

統計学 C 第 6 回目分析レポート

2025-12-08

```
library(tidyverse)

# データの読み込み
data <- read_csv("PY140.csv")

# --- 柔軟な数値抽出関数の定義 ---
# 文字列から最初の数字を抜き出し、失敗したら NA を返す
extract_num <- function(x) {
  num <- str_extract(x, "\\d+")
  return(as.numeric(num))
}

# --- 1. 労働時間 (JC_41 または ZQ05 を探す) ---
# ラベル情報に基づき、就業時間に関連する列を自動取得
work_col <- colnames(data)[grepl("JC_41|ZQ05", colnames(data))][1]
data$work_hours <- extract_num(data[[work_col]])

# --- 2. 年収 (ZQ47A) の数値化 ---
# 文字列のパターンに依存せず、冒頭の数字 (01, 02...) を取得してランク化
income_col <- colnames(data)[grepl("ZQ47A", colnames(data))][1]
income_rank <- extract_num(data[[income_col]])

# ランク (1~13) を講義資料に基づき金額 (万円) に変換 [cite: 30]
data$income <- case_when(
  income_rank == 1 ~ 0,
  income_rank == 2 ~ 50,
  income_rank == 3 ~ 150,
  income_rank == 4 ~ 250,
  income_rank == 5 ~ 350,
  income_rank == 6 ~ 450,
  income_rank == 7 ~ 550,
  income_rank == 8 ~ 700,
```

```

income_rank == 9 ~ 900,
income_rank == 10 ~ 1250,
income_rank == 11 ~ 1750,
income_rank == 12 ~ 2250,
income_rank == 13 ~ 2500,
TRUE ~ NA_real_
)

# --- 3. 年齢 (ybirth: 生年から計算、または ZQ14 等から取得) ---
# 本人の年齢が見当たらない場合、2025 年から生年を引いて算出
if (any(grepl("ybirth", colnames(data)))) {
  data$age <- 2025 - extract_num(data$ybirth)
} else {
  data$age <- extract_num(data[[colnames(data)[grepl("ZQ", colnames(data))][1]]])
}


# --- エラー防止：描画前に NA を除去したサブセットを作る ---
plot_data <- data %>% filter(!is.na(work_hours), !is.na(income))

# 確認用
cat(" 有効なサンプルサイズ:", nrow(plot_data), "\n")

## 有効なサンプルサイズ: 3114

# 散布図で視覚化 [cite: 7]
plot(data$work_hours, data$income,
      main=" 労働時間と年収の散布図",
      xlab=" 週あたり就業時間", ylab=" 年収 (万円)")

```



```
# 相関係数の算出 [cite: 262, 264]
```

```
cor.test(data$work_hours, data$income)
```

```
##
## Pearson's product-moment correlation
##
## data: data$work_hours and data$income
## t = -30.809, df = 3112, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.5099118 -0.4560646
## sample estimates:
## cor
## -0.4834454
```


```
# 分析用データセットの作成（欠損値除外）
```

```
a.data <- data.frame(
  work_hours = data$work_hours,
  income = data$income,
  age = data$age
```

```
) %>% na.omit()
```

```
# 三変数のパネル図
```

```
pairs.panels(a.data)
```



```
# 年齢を制御した偏相関係数 [cite: 595, 597]
```

```
pcor.test(a.data$work_hours, a.data$income, a.data[,c("age")], method="pearson")
```

```
##      estimate      p.value statistic      n gp Method
## 1 -0.4998563 1.751267e-196 -32.19015 3114 1 pearson
```