

統計学 C 第 6 回目分析レポート

2025-12-08

```
library(tidyverse)
library(haven) # .dta や .sav を読むために必須

# 1. データの読み込み
# ファイルが存在するかチェックしてから読み込みます
if (file.exists("PY140.sav")) {
  # SAVファイルの場合
  df <- read_sav("PY140.sav")
} else if (file.exists("PY140.dta")) {
  # DTAファイルの場合
  df <- read_dta("PY140.dta")
} else {
  stop("ファイルが見つかりません。PY140.sav または PY140.dta を同じフォルダに置いてください。")
}

# 2. 変数の抽出と加工
# havenで読み込むと「ラベル付きデータ」になるため、as.numericで数値化します

# 労働時間 (ZQ05 または JC_41などを想定)
# 実際にデータにある列名を探します
work_cols <- grep("ZQ05|JC_41|ZQ46", names(df), value = TRUE)
if(length(work_cols) > 0) {
  df$work_hours <- as.numeric(df[[work_cols[1]]])
} else {
  # 見つからない場合は強制的に NA
  df$work_hours <- NA
}

# 外れ値の処理 (100時間以上は除外など)
df$work_hours[df$work_hours > 100] <- NA

# 年収 (ZQ47A)
# SAV/DTA なら中身は「1, 2, ...」という数値コードの可能性が高いです
```

```

if("ZQ47A" %in% names(df)) {
  df$income <- car::recode(as.numeric(df$ZQ47A),
    '1=0; 2=12.5; 3=50; 4=100; 5=200; 6=300; 7=400;
    8=500; 9=700; 10=1000; 11=1500; 12=2000; 13=2500; else=NA')
} else {
  df$income <- NA
}

# 年齢 (ZQ02 または ZQ2)
age_cols <- grep("ZQ0?2", names(df), value = TRUE) # ZQ2, ZQ02 どちらも探す
if(length(age_cols) > 0) {
  df$age <- as.numeric(df[[age_cols[1]]])
} else {
  df$age <- NA
}

# 3. 分析用データの作成
# data ではなく a.data を作成
a.data <- data.frame(
  work_hours = df$work_hours,
  income = df$income,
  age = df$age
) %>% na.omit()

# 読み込み結果の確認
print(paste("有効サンプルサイズ:", nrow(a.data)))

```

```
## [1] "有効サンプルサイズ: 3114"
```

```
head(a.data)
```

```
##   work_hours income age
## 1         8     300   1
## 2         8     300   1
## 3         8     100   1
## 4         6      50   1
## 5         8     400   1
## 6         8     200   1
```


```

# data$work_hours ではなく a.data$work_hours を使います
# (prepare_data で na.omit したきれいなデータです)

```

1. 散布図の描画

```
plot(a.data$work_hours, a.data$income,
     main = " 労働時間と年収の散布図",
     xlab = " 週あたり就業時間",
     ylab = " 年収 (万円)",
     pch = 16,      # 点の形 (塗りつぶし円)
     col = "blue")  # 点の色
```



2. 相関係数の算出

```
cor_result <- cor.test(a.data$work_hours, a.data$income)
print(cor_result)
```

```
##
## Pearson's product-moment correlation
##
## data:  a.data$work_hours and a.data$income
## t = -24.351, df = 3112, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
```


```
## -0.4291586 -0.3701401
## sample estimates:
##      cor
## -0.400064
```

前のステップで作った *a.data* をそのまま使います

1. 3変数の関係を可視化 (パネル図)

psych パッケージの機能で、散布図・ヒストグラム・相関をまとめて表示します

```
psych::pairs.panels(a.data)
```



2. 年齢を制御した偏相関係数

ppcor パッケージを使います

X=労働時間, *Y*=年収, *Z*=年齢 (制御変数)

```
pcor_result <- ppcor::pcor.test(a.data$work_hours, a.data$income, a.data$age, method="pearson")
```

結果の表示

```
print(pcor_result)
```

```
##      estimate      p.value statistic      n gp Method
## 1 -0.3993661 1.503763e-119 -24.29688 3114 1 pearson
```

```

library(ggplot2)
library(dplyr)
library(haven)

# 1. データの準備
jc_col_name <- grep("JC_1", names(df), value = TRUE)[1]

if(!is.na(jc_col_name)) {
  status_label <- as_factor(df[[jc_col_name]])

  strat_data <- data.frame(
    work_hours = df$work_hours,
    income = df$income,
    raw_status = status_label
  )

  strat_data$status <- case_when(
    grepl(" 正規", strat_data$raw_status) ~ "Regular (正社員)",
    grepl(" パート | アルバイト | 派遣 | 契約 | 嘱託", strat_data$raw_status) ~ "Non-Regular (非正規)",
    TRUE ~ NA_character_ # 経営者は除外するので NA 扱いで OK
  )

  # --- 修正ポイント：外れ値を厳しくカット ---
  # 外れ値処理の強化版
  strat_data <- strat_data %>%
    filter(!is.na(work_hours) & !is.na(income) & !is.na(status)) %>%
    filter(work_hours < 80) %>% # 週 80 時間以上を除外（過労死ライン超えの外れ値）
    filter(!(status == "Regular (正社員)" & income < 150)) # 正規で年収 150 万未満を除外（途中入社などを想定）

  # 2. グラフ描画
  print(
    ggplot(strat_data, aes(x = work_hours, y = income, color = status)) +
    geom_point(alpha = 0.5) +
    geom_smooth(method = "lm", se = FALSE) +
    labs(title = " 正規 vs 非正規：労働時間と年収（週 80 時間未満） ",
         x = " 週あたり労働時間",
         y = " 年収（万円） ",
         color = " 雇用形態") +
    theme_minimal()
  )

```


```

)

# 3. 相関係数の再計算
print(
  strat_data %>%
  group_by(status) %>%
  summarise(
    Correlation = cor(work_hours, income),
    Count = n()
  )
)

} else {
  print("JC_1 変数が見つかりません")
}

```



```

## # A tibble: 2 x 3
##   status          Correlation Count
##   <chr>          <dbl> <int>

```

## 1 Non-Regular (非正規)	0.473	572
## 2 Regular (正社員)	0.183	12