

重回帰分析レポート：顧客満足度データの解析

Ryuji Uozumi (Based on Lecture Materials)

2025-12-20

```
# --- データの読み込み ---
csdata <- read.csv("CS.csv")

head(csdata, 3)

##   ID   y  x2  x3  x4  x5  x6  x7  x8
## 1  1 595 4.2 5.4 5.9 6.8 12   0   1
## 2  2 483 4.7 4.1 3.6 6.1 11   0   0
## 3  3 601 7.5 6.3 5.5 5.6 11   1   0

# データ件数の確認 [cite: 1022]
nrow(csdata)

## [1] 30

# モデルの定義と実行 [cite: 1032]
# y: 顧客数
fit1 <- lm(y ~ x2 + x3 + x4 + x5, data = csdata)

# 結果の要約（偏回帰係数、t 値、p 値、決定係数など） [cite: 1033]
summary(fit1)

##
## Call:
## lm(formula = y ~ x2 + x3 + x4 + x5, data = csdata)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -63.636 -36.548  -0.314   21.419 101.890
##
## Coefficients:
```

```
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept) -35.204      50.659  -0.695  0.49351
## x2           29.105       5.684   5.120 2.73e-05 ***
## x3           21.640       7.036   3.076  0.00503 **
## x4           23.803       6.971   3.414  0.00219 **
## x5           32.421       5.608   5.781 5.01e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 45.11 on 25 degrees of freedom
## Multiple R-squared:  0.8248, Adjusted R-squared:  0.7968
## F-statistic: 29.43 on 4 and 25 DF,  p-value: 3.957e-09
```

決定係数が0.82とモデルのほとんどを説明できていないP値もほぼ0となっておりモデルとして意味があるとは言えない。(0.05未満なら意味がある。)

分散分析表の出力

```
anova(fit1)
```

```
## Analysis of Variance Table
##
## Response: y
##           Df Sum Sq Mean Sq F value    Pr(>F)
## x2           1  49938   49938   24.537 4.204e-05 ***
## x3           1  96538   96538   47.434 3.217e-07 ***
## x4           1  25043   25043   12.305  0.001731 **
## x5           1  68028   68028   33.426 5.015e-06 ***
## Residuals  25  50880    2035
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

または資料通りの記述: `anova(aov(y ~ x2 + x3 + x4 + x5, data=csdata))`

VIFの計算 (carパッケージが必要) [cite: 1101, 1114]

```
if(require("car")){
  vif(fit1)
} else {
  print("car パッケージがインストールされていません。")
}
```

```
##           x2           x3           x4           x5
## 1.042106 1.589938 1.548752 1.010455
```

VIF は説明変数同士の相関の強さを示すが、一般的には 10 以上で問題視される。すべての変数が 2 以下程度なので今回は各変数同士は独立であると見なしてよい

```
# ダミー変数を追加したモデルの実行 [cite: 1128]
fit2 <- lm(y ~ x2 + x3 + x4 + x5 + x7 + x8, data = csdata)

# 結果の要約 [cite: 1132]
summary(fit2)

##
## Call:
## lm(formula = y ~ x2 + x3 + x4 + x5 + x7 + x8, data = csdata)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -78.543 -25.702  -2.392  17.573  91.820
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -13.878     48.906  -0.284  0.77913
## x2             27.488       5.544   4.958 5.18e-05 ***
## x3             24.745       6.779   3.650  0.00134 **
## x4             17.963       7.067   2.542  0.01822 *
## x5             28.515       5.592   5.099 3.65e-05 ***
## x7              8.014      16.121   0.497  0.62383
## x8            40.128      18.065   2.221  0.03646 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 42.55 on 23 degrees of freedom
## Multiple R-squared:  0.8566, Adjusted R-squared:  0.8192
## F-statistic: 22.9 on 6 and 23 DF, p-value: 1.27e-08
```

自由度調整済み決定係数がダミー変数を追加したことで少し改善している

```
# 各モデルの指標を比較
# fit1: 量的変数のみ
# fit2: ダミー変数あり

# 指標を取得する関数を定義
get_metrics <- function(model, name) {
```

```

s <- summary(model)
data.frame(
  Model = name,
  R_squared = s$r.squared,
  Adj_R_squared = s$adj.r.squared,
  AIC = AIC(model)
)
}

# 比較表の作成
metrics <- rbind(
  get_metrics(fit1, "Model 1 (x2-x5)"),
  get_metrics(fit2, "Model 2 (x2-x5, x7, x8)")
)

print(metrics)

```

```

##              Model R_squared Adj_R_squared      AIC
## 1      Model 1 (x2-x5) 0.8248096      0.7967792 320.2172
## 2 Model 2 (x2-x5, x7, x8) 0.8565937      0.8191834 318.2114

```

AIC が小さいほどいいモデルとされるのでモデル 2 の方がモデル 1 よりいいモデルである。