

重回帰分析レポート：変数選択とモデル比較

Ryuji Uozumi (Based on Lecture Materials)

2025-12-23

```
# --- データの読み込み ---
```

```
csdata <- read.csv("CS.csv")
```

```
head(csdata, 3)
```

```
##   ID   y  x2  x3  x4  x5  x6  x7  x8
## 1  1 595 4.2 5.4 5.9 6.8 12   0   1
## 2  2 483 4.7 4.1 3.6 6.1 11   0   0
## 3  3 601 7.5 6.3 5.5 5.6 11   1   0
```

```
# データ件数の確認 [cite: 1022]
```

```
nrow(csdata)
```

```
## [1] 30
```

```
# モデルの定義と実行 [cite: 1032]
```

```
# y: 顧客数
```

```
fit1 <- lm(y ~ x2+x3+x4+x5, data = csdata)
```

```
# 結果の要約（偏回帰係数、t 値、p 値、決定係数など） [cite: 1033]
```

```
summary(fit1)
```

```
##
```

```
## Call:
```

```
## lm(formula = y ~ x2 + x3 + x4 + x5, data = csdata)
```

```
##
```

```
## Residuals:
```

```
##      Min       1Q   Median       3Q      Max
## -63.636 -36.548  -0.314   21.419  101.890
```

```
##
```

```
## Coefficients:
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -35.204      50.659  -0.695  0.49351
## x2            29.105       5.684   5.120 2.73e-05 ***
## x3            21.640       7.036   3.076  0.00503 **
## x4            23.803       6.971   3.414  0.00219 **
## x5            32.421       5.608   5.781 5.01e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 45.11 on 25 degrees of freedom
## Multiple R-squared:  0.8248, Adjusted R-squared:  0.7968
## F-statistic: 29.43 on 4 and 25 DF,  p-value: 3.957e-09
```

決定係数が0.82とモデルのほとんどを説明できている。P値もほぼ0となっておりモデルとして意味があると言える。(0.05未満なら意味がある。)

分散分析表の出力

```
anova(fit1)
```

```
## Analysis of Variance Table
##
## Response: y
##          Df Sum Sq Mean Sq F value    Pr(>F)
## x2         1  49938   49938    24.537 4.204e-05 ***
## x3         1  96538   96538    47.434 3.217e-07 ***
## x4         1  25043   25043    12.305  0.001731 **
## x5         1  68028   68028    33.426 5.015e-06 ***
## Residuals 25  50880    2035
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

または資料通りの記述: `anova(aov(y ~ x2 + x3 + x4 + x5, data=csdata))`

VIFの計算 (carパッケージが必要) [cite: 1101, 1114]

```
if(require("car")){
  vif(fit1)
} else {
  print("car パッケージがインストールされていません。")
}
```

```
##          x2          x3          x4          x5
## 1.042106 1.589938 1.548752 1.010455
```

VIF は説明変数同士の相関の強さを示すが、一般的には 10 以上で問題視される。すべての変数が 2 以下程度なので今回は各変数同士は独立であると見なしてよい

```
# x5 と x6 の相関係数を確認
cor(csddata$x5, csdata$x6)
```

```
## [1] 0.9843212
```

```
# x5 と x6 を入れたモデルで VIFを確認
library(car)
vif(lm(y ~ x5 + x6, data = csdata))
```

```
##          x5          x6
## 32.14226 32.14226
```

```
# ダミー変数を追加したモデルの実行 [cite: 1128]
fit2 <- lm(y ~ x2 + x3 + x4 + x5 + x7 + x8, data = csdata)

# 結果の要約 [cite: 1132]
summary(fit2)
```

```
##
## Call:
## lm(formula = y ~ x2 + x3 + x4 + x5 + x7 + x8, data = csdata)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -78.543 -25.702  -2.392  17.573  91.820
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -13.878     48.906  -0.284  0.77913
## x2             27.488      5.544   4.958 5.18e-05 ***
## x3             24.745      6.779   3.650  0.00134 **
## x4             17.963      7.067   2.542  0.01822 *
## x5             28.515      5.592   5.099 3.65e-05 ***
## x7              8.014     16.121   0.497  0.62383
## x8            40.128     18.065   2.221  0.03646 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 42.55 on 23 degrees of freedom
```

```
## Multiple R-squared:  0.8566, Adjusted R-squared:  0.8192
## F-statistic:  22.9 on 6 and 23 DF,  p-value: 1.27e-08
```

自由度調整済み決定係数がダミー変数を追加したことですこし改善している

```
# 各モデルの指標を比較
# fit1: 量的変数のみ
# fit2: ダミー変数あり

# 指標を取得する関数を定義
get_metrics <- function(model, name) {
  s <- summary(model)
  data.frame(
    Model = name,
    R_squared = s$r.squared,
    Adj_R_squared = s$adj.r.squared,
    AIC = extractAIC(model)
  )
}

# 比較表の作成
metrics <- rbind(
  get_metrics(fit1, "Model 1 (x2-x5)"),
  get_metrics(fit2, "Model 2 (x2-x5, x7, x8)")
)

print(metrics)
```

```
##              Model R_squared Adj_R_squared      AIC
## 1      Model 1 (x2-x5) 0.8248096      0.7967792    5.0000
## 2      Model 1 (x2-x5) 0.8248096      0.7967792 233.0808
## 3 Model 2 (x2-x5, x7, x8) 0.8565937      0.8191834    7.0000
## 4 Model 2 (x2-x5, x7, x8) 0.8565937      0.8191834 231.0751
```

AIC が小さいほどいいモデルとされるのでモデル 2 の方がモデル 1 よりいいモデルである。

```
# 1. 比較に使用する説明変数のリスト
# 資料に基づき x2~x6 を使用します
vars <- c("x2", "x3", "x4", "x5", "x6")

# 2. 結果を格納する空のデータフレームを作成
results_df <- data.frame()
```

```

# 3. ループ処理で全ての組み合わせのモデルを作成
for (k in 1:length(vars)) {

  # 変数から k 個選ぶ組み合わせを生成
  combos <- combn(vars, k, simplify = FALSE)

  # 各組み合わせについてモデルを作成
  for (combo in combos) {

    # フォーミュラ（回帰式）の作成
    formula_str <- paste("y ~", paste(combo, collapse = " + "))

    # モデルの実行
    model <- lm(as.formula(formula_str), data = csdata)

    # 統計量の取得
    s <- summary(model)

    # extractAICの結果を取得（2番目の値がAIC）
    # 重要: ここで必ず fit1 ではなく model を使うこと！
    aic_val <- extractAIC(model)[2]

    # 結果を1行のデータとしてまとめる
    row <- data.frame(
      Model = paste(combo, collapse = ", "),
      R_squared = s$r.squared,
      Adj_R_squared = s$adj.r.squared,
      AIC = aic_val
    )

    # 結果テーブルに追加
    results_df <- rbind(results_df, row)
  }
}

# 4. 見やすいように列名を調整
colnames(results_df) <- c("使用変数", "決定係数 (R2)", "調整済み R2", "AIC")

# 5. AICが小さい順に並べ替え（良いモデル順）

```

```
results_df <- results_df[order(results_df$AIC), ]
```

6. 表の出力

```
kable(results_df, caption = "変数組み合わせごとのモデル評価指標 (AIC 昇順)", digits = 4)
```

表1: 変数組み合わせごとのモデル評価指標 (AIC 昇順)

	使用変数	決定係数 (R2)	調整済み R2	AIC
26	x2, x3, x4, x5	0.8248	0.7968	233.0808
27	x2, x3, x4, x6	0.8150	0.7853	234.7228
31	x2, x3, x4, x5, x6	0.8252	0.7888	235.0131
20	x2, x4, x6	0.7603	0.7326	240.4890
19	x2, x4, x5	0.7585	0.7307	240.7085
29	x2, x4, x5, x6	0.7615	0.7233	242.3414
17	x2, x3, x5	0.7431	0.7135	242.5639
28	x2, x3, x5, x6	0.7509	0.7111	243.6366
18	x2, x3, x6	0.7213	0.6892	245.0042
22	x3, x4, x5	0.6411	0.5997	252.5968
13	x4, x5	0.6098	0.5809	253.1034
14	x4, x6	0.6034	0.5741	253.5887
23	x3, x4, x6	0.6263	0.5832	253.8055
30	x3, x4, x5, x6	0.6430	0.5859	254.4343
25	x4, x5, x6	0.6099	0.5649	255.0943
16	x2, x3, x4	0.5906	0.5433	256.5472
11	x3, x5	0.5246	0.4894	259.0274
24	x3, x5, x6	0.5410	0.4880	259.9779
7	x2, x4	0.5073	0.4708	260.1040
6	x2, x3	0.5043	0.4676	260.2808
12	x3, x6	0.4944	0.4569	260.8786
8	x2, x5	0.4622	0.4223	262.7316
9	x2, x6	0.4545	0.4141	263.1575
21	x2, x5, x6	0.4622	0.4001	264.7292
3	x4	0.3410	0.3174	266.8278
10	x3, x4	0.3827	0.3370	266.8636
4	x5	0.3097	0.2850	268.2191
5	x6	0.2929	0.2677	268.9386
15	x5, x6	0.3111	0.2600	270.1592
2	x3	0.2581	0.2316	270.3821
1	x2	0.1719	0.1424	273.6769

上記が回帰モデルの比較であるが、フルモデルよりも